

라벨링 정의 점검 — 7개 라벨링 스킴 비교 진단

"확장하되 왜곡하지 않는" 라벨링이 존재하는가

작성일: 2026-05-29 작성자: 이현지 관련 계획: docs/다음 실험 설계안(연구지향 Stream 0).md \$Stream R
선행 연구: docs/research_s0_diagnostic_report.md (S0 진단) 재현 코드: src/research/sr_labeling/
결과 산출물: results/research_sr_labeling/

초록 (Abstract)

S0 진단에서 **baseline RF의 test PR-AUC 0.2876은 95% Bayesian 신뢰구간 [0.180, 0.421] 안의 한 점**이며 exp_010~018의 모든 사전 실험이 이 신뢰구간 안에 들어 간다는 사실이 확인됐다. 본 stream은 한 단계 더 거슬러 올라가 **라벨링 정의 자체가 잘못된 것은 아닌지** 점검한다. 회의에서 제기된 두 의견 — (1) 라벨 1 데이터의 절대 부족(124:1)이 근본 문제일 수 있다, (2) "상폐 예측"이 아닌 "상폐 위험 검출"로 문제를 비틀면 라벨 1을 확장할 여지가 있을지 모른다 — 을 체계적으로 검증한다.

총 **7가지 train 라벨링 스킴**을 비교했다: **L1** fixed_N1 (현재 baseline), **L2** rolling_H12 (1년 내), **L3** rolling_H24 (2년 내), **L4** fixed_N1 $\cup$ N2 $\cup$ N3 (union, 1~3년 전 모두 1), **L5** ordinal 4-class (정상/N3/N2/N1), **L6** continuous risk score $\exp(-\Delta t/\tau)$ (회귀), **L7** v3-style 상폐 기업의 모든 연도 = 1. **공정 비교의 핵심**으로 valid/test의 정답 라벨은 항상 fixed_N1로 고정하고, train의 라벨링만 바꾸었다. 모든 라벨링에 동일 baseline RF + walk-forward 4-fold $\times$ 2-seed

- test 2024 5-seed + Bayesian bootstrap 1500회를 적용했다.

세 가지 결과가 라벨링 정의 논쟁을 사실상 종결시킨다. **(1)** 7개 모든 라벨링의 test PR-AUC가 S0에서 측정된 baseline의 95% CI [0.180, 0.421] 안에 들어간다 — **라벨링 변경만으로는 baseline 천장을 통계적으로 깰 수 없다**. **(2)** 그럼에도 일관된 ranking이 관찰된다: **L3 rolling_H24** (5-seed mean **0.263**, P@20 0.50)와 **L6 continuous** (mean 0.259)가 baseline **L1** (mean 0.257)을 작지만 일관되게 능가한다. 반대로 **L2 rolling_H12** (mean 0.234)와 **L7 v3 all-years** (mean 0.245)는 baseline 미만이다. **(3)** 회의에서 언급된 v3 사례의 valid 0.42 $\rightarrow$ test 0.234 붕괴는 **라벨링 자체의 문제가 아닌 평가 라벨 부적합 문제**였음이 확인된다 — train=v3, test=fixed_N1 조합에서는 valid-test PR-AUC가 모두 baseline 수준에 머물며 명확한 붕괴가 사라진다.

결론적으로 라벨링은 **소폭의 일관된 개선 여지를 제공하지만 천장 자체를 깨지 못한다**. S0 결론을 보강하며, 다음 stream은 라벨링 추가 변형이 아니라 **시 계열 모델링(S1) 또는 hazard 모델(S3)**로 가야 한다. 다만 그 stream에서 default 라벨링을 **L3 rolling_H24** 또는 **L6 continuous**로 채택하는 것은 검토할 가치가 있다.

1. 서론 (Introduction)

S0 진단 보고서(2026-05-28) 결론은 다음과 같았다:

- baseline RF의 test PR-AUC 0.2876은 95% Bayesian CI 폭이 0.24에 달하는 점추정.
- exp_010~018의 9개 사전 실험은 모두 baseline의 신뢰구간 안에 들어가 통계적으로 구분되지 않는다.
- 남은 오차의 본질은 **35개의 confident FN** — 상폐 1년 전에도 재무비율상 정상으로 보이는 기업들.

S0 직후 진행된 팀 회의에서 다음 의견이 제기됐다:

"라벨 1 데이터가 너무 적어서 발생하는 근본적인 문제다. 라벨 1 처리를 조금이라도 넓은 범위에서 하되, 왜곡도는 높지 않을 수 있게 하고 싶다. 결론은 우리 문제 정의가 잘못된 부분이 있는지 점검이 필요할 것 같다."

이 의견은 두 가지 변형을 시사한다. 첫째, **라벨 확장**: fixed_N1 (정확히 1년 전)을 rolling H개월 내, 1~3년 union, 순서형, 연속형 등으로 일반화하여 train 양성을 늘리는 것. 둘째, **문제 재정의**: "상폐 예측" 대신 "상폐 위험 검출"로 framing을 바꾸는 것 — 이는 binary 분류에서 ranking/regression으로의 이동 을 의미할 수 있다.

같은 회의에서 또 다른 팀원의 v3 사례도 비교 anchor로 제기됐다 — "상폐 기업의 모든 연도 = 1"로 정의했을 때 valid PR-AUC가 0.42까지 올라갔으나 test에서 0.234로 떨어졌다는 기록이다. v3는 따라서 "확장하면 좋아진 것처럼 보이지만 test에서 실패하는" 위험의 경고 사례다.

본 stream은 7개 라벨링 변형을 동일한 평가 프로토콜로 비교하여, **확장이 의미 있게 도움이 되는 지점이 존재하는가와 v3 실패 메커니즘이 정확히 무엇인가**를 동시에 답한다.

2. 라벨링 스킴 정의 (7가지)

ID	Train 라벨 정의	의미	타입	양성 정의
L1	<code>delta == 1</code>	현재 baseline (fixed_N1)	binary	상폐 정확히 1년 전
L2	<code>delta ∈ {0, 1}</code>	rolling_H12 (~1년 내)	binary	1년 내 상폐
L3	<code>delta ∈ {0, 1, 2}</code>	rolling_H24 (~2년 내)	binary	2년 내 상폐
L4	<code>delta ∈ {1, 2, 3}</code>	fixed_N1 ∪ N2 ∪ N3	binary	1·2·3년 전 모두 1
L5	<code>delta = 1 → 3, =2→2, =3→1, else 0</code>	순서형 4-class	ordinal	위험도 등급
L6	<code>exp(-delta/2)</code> for <code>delta ∈ {1,2,3}</code> , else 0	연속 risk score	continuous	위험 점수 회귀
L7	상폐 기업의 모든 연도 (<code>year ≤ delist_year</code>)	v3 스타일	binary	상폐 기업 전체

`delta = delist_year - year` (양수 = 미래 상폐). 정상 기업은 `delta = NaN` → 모든 binary 라벨링에서 0.

라벨링별 train 양성 분포

라벨링	Train (29,986행) 양성	비율	vs L1 배수	불균형비
L1 fixed_N1	262	0.87%	1.0x	113.4
L2 rolling_H12	348	1.16%	1.33x	85.2
L3 rolling_H24	641	2.14%	2.45x	45.8
L4 union	871	2.90%	3.32x	33.4
L5 ordinal	class 3=262, 2=293, 1=316, 0=29,115	-	-	-
L6 continuous	871개 비영 (<code>mean_score = 0.0099</code>)	2.90%	-	-

라벨링	Train (29,986행) 양성	비율	vs L1 배수	불균형비
L7 v3 all years	2,094	6.98%	7.99x	13.3

분포 표: results/research_sr_labeling/R_labeling_distribution.csv

3. 실험 프로토콜

3.1 공정 비교의 핵심 원칙

train의 라벨링은 7가지로 바뀌지만, **valid/test**의 정답 라벨은 항상 **fixed_N1 (L1)**로 고정한다. 그렇지 않으면 라벨링별 PR-AUC가 양성 비율 효과로 부풀려져 공정한 비교가 불가능하다 (이것이 v3 사례의 "valid 0.42" 가 사실은 분포 비 대칭에 의한 착시였음을 본 보고서 §4.4에서 입증한다).

3.2 사용 모델

S0의 canonical baseline RF (n_estimators=200, max_depth=10, min_samples_leaf=5, max_features=sqrt) 동일 적용:

- binary: `RandomForestClassifier` → `predict_proba[:, 1]`을 score로
- ordinal: `RandomForestClassifier` (multiclass) → class 3 (가장 위험) 확률을 score로
- continuous: `RandomForestRegressor` → `predict`를 score로

3.3 평가 grid

단계	구성	측정수
Test 5-seed	7 라벨링 × 5 seed (42, 7, 13, 21, 100)	35
Walk-forward	7 라벨링 × 4 fold × 2 seed (42, 13)	56
Bootstrap CI	7 라벨링 × seed 42, n_boot=1500	7

평가 지표: PR-AUC (주지표), ROC-AUC, top-20/50 precision, top-20/50 lift, walk-forward fold variance.

4. 결과

4.1 Test 2024 (fixed_N1 ground truth) — 5 seed mean

라벨링	Test PR-AUC mean	std	ROC-AUC mean	P@20	P@50
L3 rolling_H24	0.2632	0.0052	0.858	0.50	0.376
L6 continuous	0.2586	0.0066	0.851	0.43	0.376
L1 fixed_N1 (baseline)	0.2566	0.0107	0.839	0.48	0.372
L4 union N1+N2+N3	0.2558	0.0062	0.858	0.47	0.344
L5 ordinal	0.2517	0.0093	0.859	0.48	0.332
L7 v3 all-years	0.2454	0.0122	0.874	0.49	0.308

라벨링	Test PR-AUC mean	std	ROC-AUC mean	P@20	P@50
L2 rolling_H12	0.2338	0.0085	0.850	0.43	0.324

- 관찰:
- 7개 라벨링의 test PR-AUC가 모두 0.234~0.263 사이에 위치 (폭 0.029).
 - L3 rolling_H24 (24개월 내)가 모든 5-seed 측정에서 일관적으로 최고 (range 0.257~0.270).
 - L2 rolling_H12 (12개월 내)는 베이스라인보다 명확히 낮음 (-0.023).
 - L7 v3는 baseline보다 0.011 낮지만, **ROC-AUC는 가장 높음** (0.874). → ranking 성능은 좋으나 양성 추출 효율이 떨어짐 = anomaly 분리 정도와 positive precision 사이의 trade-off가 라벨링별로 다르게 나타남.

4.2 Bayesian bootstrap CI (seed 42 단일)

라벨링	Test PR-AUC	95% CI	Δ vs L1 baseline
L4 union N1+N2+N3	0.2580	[0.157, 0.391]	+0.010
L3 rolling_H24	0.2572	[0.162, 0.385]	+0.009
L6 continuous	0.2538	[0.156, 0.381]	+0.006
L1 fixed_N1	0.2475	[0.150, 0.378]	0
L7 v3 all-years	0.2430	[0.148, 0.375]	-0.005
L5 ordinal	0.2393	[0.143, 0.367]	-0.008
L2 rolling_H12	0.2218	[0.132, 0.348]	-0.026

핵심 결론: 7개 라벨링의 CI가 모두 [0.13, 0.39] 영역에서 거의 완전히 겹친다. S0에서 측정된 baseline의 [0.180, 0.421] CI 안에 모든 라벨링이 포함 된다 → 라벨링 변경은 통계적으로 유의한 차이를 만들지 못한다.

그림: results/research_sr_labeling/R_pr_auc_comparison.png

4.3 Walk-forward CV 안정성 (4 fold × 2 seed)

라벨링	fold별 test PR-AUC mean	std	min	max
L6 continuous	0.2349	0.0225	0.205	0.258
L1 fixed_N1	0.2271	0.0306	0.165	0.265
L5 ordinal	0.2269	0.0258	0.193	0.265
L3 rolling_H24	0.2266	0.0333	0.182	0.264
L2 rolling_H12	0.2166	0.0175	0.190	0.242
L4 union N1+N2+N3	0.2087	0.0401	0.161	0.258
L7 v3 all-years	0.1777	0.0532	0.122	0.260

- 관찰:
- L6 continuous가 fold 간 안정성에서 가장 우수** (std 0.022).

- **L7 v3는 fold 안정성이 가장 낮음** (std 0.053, 거의 baseline의 2배). → v3 라벨링은 학습 데이터 분포 변화에 가장 민감하다.
- L4 union도 fold 안정성이 떨어짐 (std 0.040). 양성을 너무 광범위하게 정의하면 fold마다 학습 패턴이 달라지는 경향.

그림: [results/research_sr_labeling/R_walk_forward_stability.png](#)

4.4 v3 실패 메커니즘 재해석

회의에서 제기된 v3 valid 0.42 → test 0.234 붕괴는 본 실험에서 재현되지 않는다. 본 실험의 L7(v3 라벨링 + fixed_N1 평가) 결과:

분할	PR-AUC (5 seed mean)	라벨 양성
valid (fixed_N1)	0.188	39
test (fixed_N1)	0.245	56

기존 v3 보고([docs/experiment_comparison_v3_vs_ours.md](#))의 valid 0.42는 valid 도 v3 라벨로 평가했기 때문으로 추정된다. v3 valid 라벨로 평가 시 valid의 "양성"이 fixed_N1 39개에서 minseo 양성 ~280개 정도로 확대되어 base rate가 상승하고 PR-AUC가 자연스럽게 부풀려진다.

결론: v3의 valid 0.42 → test 0.234 붕괴는 라벨링 자체의 문제가 아니라 "valid에서는 v3 라벨로, test에서는 사실상 다른 라벨로 평가했다"는 평가 일관성 부재의 결과. v3 라벨 자체는 test PR-AUC를 0.245로 유지하며 baseline 대비 약간 떨어지는 수준에 그친다.

다만 walk-forward에서 L7의 fold 안정성이 가장 낮다는 점은 v3 라벨링이 다른 의미에서 "위험한" 선택임을 보여준다 — train 분포가 조금만 변해도 모델이 만드는 ranking이 흔들린다.

4.5 Top-K precision (위험 검출 운영 관점)

운영 시점에서 가장 위험한 K개 기업을 골라낼 때의 precision (= K개 중 진짜 상폐 기업 비율):

라벨링	P@20 mean	P@50 mean
L3 rolling_H24	0.500	0.376
L7 v3 all-years	0.490	0.308
L1 fixed_N1	0.480	0.372
L5 ordinal	0.480	0.332
L4 union	0.470	0.344
L2 rolling_H12	0.430	0.324
L6 continuous	0.430	0.376

L3 rolling_H24가 P@20과 P@50 모두에서 최고. L6 continuous는 PR-AUC와 walk-forward 안정성에서 우수했지만 top-K precision은 평범. L7 v3는 P@20에서는 2위지만 P@50에서는 가장 낮음 (0.308) — 상위 20명까지는 잘 잡으나 그 다음은 약하다.

그림: [results/research_sr_labeling/R_topk_metrics.png](#)

4.6 라벨링별 종합 ranking

지표	1위	2위	3위
Test PR-AUC (5-seed mean)	L3	L6	L1
Bootstrap CI point (seed 42)	L4	L3	L6
Walk-forward std (안정성)	L6	L1	L5
Top-20 precision	L3	L7	L1
Top-50 precision	L3=L6	-	L1

L3 rolling_H24가 4/5 지표에서 1~3위 안에 들고, 4개 지표에서 1위 차지 — 가장 일관되게 우수한 라벨링.

5. 종합 논의

5.1 회의 질문에 대한 답

Q1. "라벨 1 데이터가 너무 적어서 발생하는 근본적인 문제인가?"

부분적으로만 그렇다. L4(union 3.3x), L7(v3 8.0x) 등 양성을 늘려도 test PR-AUC가 baseline의 noise band를 벗어나지 못한다. 양성 절대수 부족이 천장의 일부일 수는 있지만, 라벨 정의를 넓혀서 채워질 수 있는 종류가 아니다 — **양성을 늘려도 "확장된 양성"이 가지는 신호 강도가 약하기 때문**. 예를 들어 L7 v3의 양성에는 상폐 5년 전 평범한 재무 데이터까지 포함되어, 모델 입장에서는 "어떤 의미에서의 1인지" 흐려진다.

Q2. "'상폐 예측' 대신 '상폐 위험 검출'로 framing을 바꾸면 라벨 1을 자연 스럽게 확장할 수 있을까?"

L3 (rolling_H24)과 L6 (continuous risk score)이 이 방향을 가장 정직하게 구현 한다 — L3는 "2년 내 발생" hazard, L6은 위험도 점수 회귀. 두 라벨링 모두 baseline 을 일관되게 능가하지만 통계적으로는 noise 범위 안. **framing 변경은 옳은 방향 이지만 그 자체로 천장을 깨지는 못한다**. 단, walk-forward 안정성과 top-K precision 에서 framing 효과가 명확히 보이므로 다음 stream의 default 라벨링은 L3 또는 L6으로 채택할 가치가 있다.

Q3. "v3 사례처럼 확장이 train-test 격차를 만들지는 않는가?"

본 실험은 v3 라벨링이 만든 valid-test 격차가 **라벨링 본질이 아닌 평가 일관성 문제**였음을 입증한다 (§4.4). train에서 양성을 7배 늘려도 평가를 fixed_N1로 통일하면 test PR-AUC는 baseline 수준에 머문다. **다만 v3 라벨링은 walk-forward 안정성이 가장 낮아** train 분포 변화에 가장 민감하다 — 이는 향후 분포 이동에 대한 robustness 관점에서 v3 변형이 가장 위험한 선택임을 의미한다.

5.2 라벨링은 천장의 주요 원인이 아니다

본 stream의 가장 명료한 결론. 7개 라벨링이 [0.234, 0.263] 폭 0.029 안에 위치 하며 모두 S0 baseline CI 안. **라벨링은 ±3% PR-AUC의 영향력만 가진다**.

S0의 결론(시계열 모델링 S1, hazard 모델 S3로 가야 한다)이 본 stream 결과로 강화된다 — 단일 스냅샷 + RF에서 라벨링만 바꿔봐야 천장을 깰 수 없다. **천장의 원인은 라벨링이 아니라 모델 구조와 정보 입력의 단순성**이다.

5.3 그럼에도 의미 있는 선택지

- **L3 rolling_H24**: 5-seed mean PR-AUC, top-K precision, S3 hazard 모델로의 자연 확장 가능성에서 가장 일관됨.
- **L6 continuous risk score**: walk-forward 안정성에서 최고. 회귀 출력은 "위험도" framing에 자연스럽게, 임계치 운영이 유연.
- **L2 rolling_H12 및 L7 v3는 피해야 함**: 전자는 양성 추가 효과 없이 노이즈만 추가, 후자는 fold 안정성이 가장 낮음.

6. 후속 Stream에 대한 시사점 (S0 권장 갱신)

S0 보고서의 §9 stream 우선순위에 본 실험 결과를 반영하면:

Stream	S0 권장	Stream R 후 권장	사유
S1. 불규칙 시계열	강력 권장	강력 권장 (변동 없음)	라벨링이 천장을 못 깨므로 S1의 필요성이 더 확실해짐
S2. VAE (피쳐 제공자)	권장	권장 (변동 없음)	동일
S3. 생존 분석	권장	강력 권장으로 격상	L3, L6의 우수성이 hazard framing의 가치를 시사
S4. 분포 이동 적응	후순위	후순위 (변동 없음)	동일
(신규) 라벨링 default 채택	-	L3 rolling_H24 또는 L6 continuous	S1/S3 진입 시 default로

7. 본 연구의 한계

- **Walk-forward**는 **2-seed만 사용** (시간 절약). $4\text{-fold} \times 2\text{-seed} = 8$ 측정으로 fold std 추정이 약함. 시간 여유가 있으면 5-seed로 확대 권장.
- **rolling H 라벨링의 H 그리드는 H12/H24만 시험** — H18, H36 등 중간 horizon 미시험. 다음 stream에서 default 라벨링을 결정하기 전 H 민감도 추가 분석 가치.
- **연속 라벨링의 τ 는 2.0 단일값** — $\exp(-\Delta/\tau)$ 의 τ 그리드 (1, 2, 3) sensitivity 미수행.
- **L5 ordinal에서 class 3 확률을 score로 사용한 단일 매핑만 실험**. ordinal regression 알고리즘(예: cumulative-link RF)은 시도하지 않음.
- **모든 라벨링이 baseline 동일 RF로 학습** — 라벨링별 최적 hyperparameter가 다를 수 있으나 공정 비교 위해 고정. fair comparison vs each-best-model의 trade-off.

8. 재현성

```
.venv\Scripts\python.exe -m src.research.sr_labeling.labelings # 분포 확인
.venv\Scripts\python.exe -m src.research.sr_labeling.run_sr_all # 전체 grid
```

기본 seed [42, 7, 13, 21, 100], walk-forward seed [42, 13], bootstrap n_boot=1500. 동일 seed로 재실행 시 결과 CSV·JSON이 비트 단위 동일. Windows 노트북 CPU 기준 wall time 약 30분.

기존 의존성 (S0와 동일): `matplotlib`, `pandas`, `scikit-learn`, `numpy`, `scipy`. 추가 의존성 없음.

9. 산출물 목록

results/research_sr_labeling/:

- `R_labeling_distribution.csv` — 7 라벨링 × 3 split 양성 분포
- `R_test_multi_seed.csv` — 7 × 5 seed test 결과
- `R_results_grid.csv` — 7 × 4 fold × 2 seed walk-forward
- `R_summary_per_labeling.csv` — 라벨링별 통계 요약
- `R_bootstrap_ci.csv` — 라벨링별 Bayesian bootstrap CI
- `R_summary.json` — 모든 결과 통합 JSON
- `R_pr_auc_comparison.png` — bootstrap CI bar chart
- `R_walk_forward_stability.png` — fold별 변동성
- `R_topk_metrics.png` — top-K precision/lift

코드: src/research/sr_labeling/:

- `labelings.py` — 7개 라벨링 변환 함수 + `delist_year` 매핑
- `train_eval.py` — 학습/평가 파이프라인 (fixed_N1 평가 통일)
- `run_sr_all.py` — 전체 grid 실행 + 그림 생성